

АНАЛИТИЧЕСКИЙ ОТЧЕТ

Разработка и валидация моделей машинного обучения для прогнозирования биологической активности (IC_{50}), цитотоксичности (CC_{50}) и индекса селективности (SI)

1. Постановка задачи и методология

Цель исследования — оценка возможности применения алгоритмов классического машинного обучения для предсказания фармакологических параметров соединений по их 2D-молекулярным дескрипторам RDKit (215 признаков, 1001 молекула).

Исследование выполнялось поэтапно в рамках 8 специализированных ноутбуков (0_EDA — 7_Classification_SI_threshold8):

- **Предварительная обработка данных:** Анализ распределений, очистка от признаков с близкой к нулю дисперсией ($VarianceThreshold(0.01)$), стандартизация, генерация полиномиальных комбинаций ключевых параметров ($MolWt$, $MolLogP$).
- **Регрессия (Задачи 1–3):** Количественное предсказание непрерывных значений IC_{50} , CC_{50} и SI .
- **Бинарная классификация (Задачи 4–7):** Разделение соединений на активные/неактивные с использованием медианных сплитов и биологически обоснованного порога ($SI > 8.0$).

2. Сводные результаты моделирования

В таблице представлены наилучшие алгоритмы для каждой из исследованных задач по результатам кросс-валидации и тестирования:

Задача / Ноутбук	Таргет	Формат задачи	Порог деления	Лучшая модель	R2 / ROC-AUC	F1-score / RMSE
Notebook 1	IC_{50}	Регрессия	—	CatBoost	$R^2 = 0.312$	$RMSE = 384.2$
Notebook 2	CC_{50}	Регрессия	—	CatBoost	$R^2 = 0.468$	$RMSE = 512.1$
Notebook 3	SI	Регрессия	—	Gradient Boosting	$R^2 = 0.185$	$RMSE = 841.5$

Notebook 4	IC_{50}	Классификация	Медиана (46.58 мМ)	CatBoost	$\text{AU C} = 0.793$	$F1 = 0.731$
Notebook 5	CC_{50}	Классификация	Медиана (411.04 мМ)	CatBoost	$\text{AU C} = 0.850$	$F1 = 0.738$
Notebook 6	SI	Классификация	Медиана (3.85)	KNN	$\text{AU C} = 0.705$	$F1 = 0.673$
Notebook 7	SI	Классификация	Биологический ($SI > 8.0$)	KNN	$\text{AU C} = 0.753$	$F1 = 0.615$

3. Анализ и интерпретация результатов

Ограничения регрессионного подхода

Прямое предсказание количественных значений показало низкую точность (максимальный $R^2 = 0.468$ для CC_{50} и $R^2 < 0.20$ для SI). Основная причина — тяжелые правые хвосты распределений (асимметрия $SI > 17$) и специфический шум экспериментальных биологических измерений *in vitro*. Даже при логарифмировании ([log1p](#)) регрессионные модели склонны сглаживать предсказания к среднему, теряя пиковые значения.

Эффективность бинарной классификации

Переход к бинарным меткам существенно повысил устойчивость моделей:

- Предсказание цитотоксичности (CC_{50}):** Модели демонстрируют наивысшую точность (ROC-AUC = 0.850). Общая токсичность сильно завязана на базовые физико-химические свойства молекулы (липофильность [MolLogP](#), вес [MolWt](#)), которые хорошо улавливаются градиентным бустингом.
- Предсказание селективности (SI):** Использование четкого биологического порога ($SI > 8.0$) показало себя более обоснованным, чем медианный сплит (ROC-AUC 0.753 против 0.705).

Аномалия метрики KNN на индексе селективности

На задачах бинаризации SI алгоритм **KNN** систематически обгонял сложные ансамбли (CatBoost, Random Forest). В хемоинформатике это объясняется «принципом молекулярного подобия» (Molecular Similarity Principle): структурно близкие молекулы с похожими 2D-дескрипторами чаще обладают схожим индексом селективности, что позволяет метрическим алгоритмам работать эффективнее деревьев решений в локальных областях пространства признаков.

4. Практические рекомендации и развитие проекта

1. **Применение в виртуальном скрининге:** Разработанную связку из **CatBoost** (для фильтрации токсичных соединений по CC_{50}) и **KNN** (для отбора селективных кандидатов с $SI > 8$) рекомендуется использовать на первом этапе виртуального скрининга для отсева неперспективных веществ.
2. **Управление дисбалансом:** При пороге $SI > 8.0$ наблюдается дисбаланс классов (64% / 36%). При дальнейшем жестком повышении порога ($SI > 10$) необходимо внедрять методы взвешивания классов (`class_weight='balanced'`) или подбор порога вероятности (decision threshold tuning) под задачи минимизации False Negative.
3. **Перспективы улучшения:** Для повышения прогностической точности целесообразен переход от плоских 2D-дескрипторов к векторным представлениям структур (Morgan Fingerprints) или графовым нейронным сетям (GNN).